Hesaplamali Anlambilim 2. Ödev

LLM Trajectory Analysis

Hamza Vedat Cengiz

Nisan 2026

Problem

Odevin ana fikri

Dil modelinin sadece **urettigi metne** degil, metni uretirken iceride olusan **temsil hareketine** bakiyoruz.

- Iki farkli causal language model secildi.
- Her model icin en az 1000 trajectory toplandi.
- Her trajectory en az 50 tokenlik uretimden olustu.
- Trajectory'lerden ozellik cikarilip iki tahmin gorevi kuruldu.

Temel Kavramlar

Token

Modelin metni islerken kullandigi parcadir. Her zaman tam kelime olmak zorunda degildir.

Trajectory

Uretim sirasinda her adimda son-token hidden state'i kaydedilirse zaman icinde bir vektor dizisi olusur.

Hidden state

Modelin o andaki ic sayisal durumu. Bir sonraki token seciminden hemen onceki vektor temsilidir.

Yazilimci benzetmesi

Bir servisin loglarini degil, runtime ic durumunun zaman serisini inceliyoruz.

Kullandigim Modeller ve Veri

- Modeller: `gpt2` ve `EleutherAI/pythia-70m`
- Toplam trajectory sayisi: **2000**
- Model basina trajectory: **1000**
- Kategori sayisi: **5**
- Kategoriler: History, Science, Technology, Art, Sports
- Uretim uzunlugu: **50 token**

Neden iki gorev kuruldu?

Trajectory ozellikleri model kimligini ve prompt kategorisini ne kadar tasiyor, bunu gormek icin.

Pipeline

1. Prompt verildi.
2. Model token token uretim yapti.
3. Her adimda son-layer son-token hidden state kaydedildi.
4. Her ornek icin bir trajectory dosyasi olustu.
5. Trajectory'lerden geometric ve normalized/scale-invariant feature'lar cikarildi.
6. Siniflandirma deneyleri calistirildi.
7. Sonuclar raporlandi ve gorsellestirildi.

Kod dosyalari

`collect_data.py`, `extract_features.py`, `predict.py`, `visualize.py`

Tahmin Gorevleri

Gorev 1: Model identity

Soru: Bu trajectory hangi modelden geldi?

- siniflar: GPT-2 vs Pythia-70M
- amac: trajectory model imzasi tasiyor mu?

Gorev 2: Prompt category

Soru: Bu trajectory hangi kategoriye ait?

- 5 kategori
- grouped split kullanildi
- prompt template leakage azaltildi

Feature Sets

Kullanilan feature aileleri

- **Raw geometric**: adimlar arasi mesafe, yol uzunlugu, linearity
- **Normalized geometric**: olcek etkisini azaltan geometric ozetler
- **Scale-invariant**: goreli degisim ve donus davranisini ozetleyen feature'lar

- Raw sonuclar sadece baseline olarak kullanildi.
- Ana yorum normalized + scale-invariant feature'lar uzerinden yapildi.
- Category prediction icin grouped split coverage kontrolu eklendi.

Gorsellestirme 1: Model Bazli Trajectory Panelleri

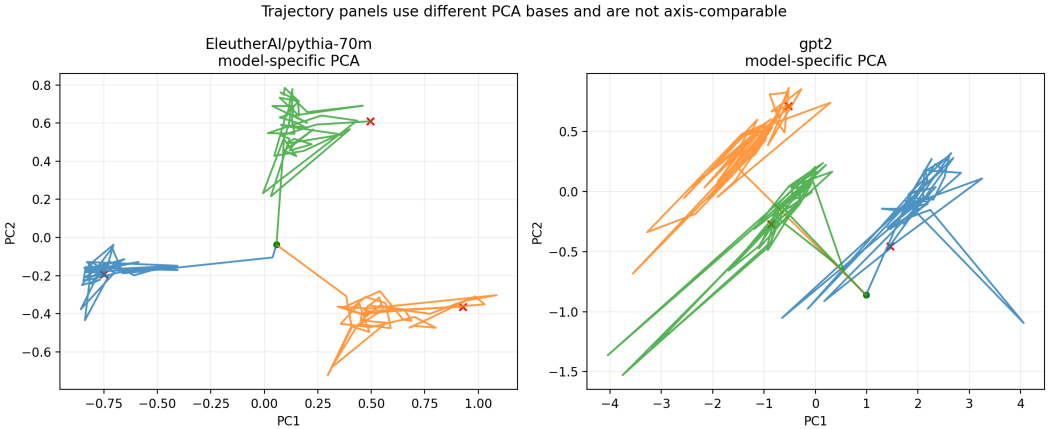

Her panel model-ozel PCA bazinda cizildi. Panellerin eksenleri birebir karsilastirilmaz; amac her modelin kendi icindeki trajectory davranisini gormektir.

Gorsellestirme 2: Ortak Feature Space

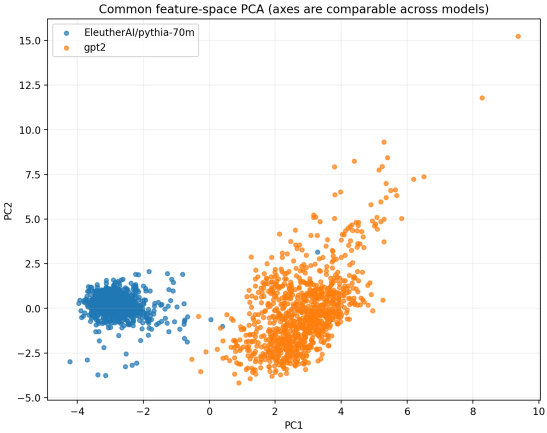

Bu PCA ortak feature uzayinda cizildi, bu nedenle modeller arasi dagilim farki ayni koordinat sisteminde okunabilir.

Sayisal Sonuclar

Gorev ve setting	Random Forest	Logistic Regression
Model identity (raw)	1.0000	1.0000
Model identity (normalized main)	**0.9975**	**1.0000**
Category (grouped, raw)	0.2405	0.2095
Category (grouped, normalized main)	**0.2143**	**0.2071**

Coverage kontrolu

Grouped split coverage satisfied = **True**

Yorum

- Model identity sonucu neredeyse kusursuz: trajectory'ler model bazli guclu bir imza tasiyor.
- Category sonucu dusuk: mevcut feature set ile kategori bilgisi belirgin sekilde ayrismiyor.
- 5 kategori oldugu icin category task'ta sonuc neredeyse sans seviyesine yakin.
- Bu, trajectory'lerin once model dinamikleri tarafindan sekillendigini dusundurebilir.

Kisa yorum

Modelin **hangi model oldugu** trajectory'den cok iyi anlasiliyor; ancak **hangi konu kategorisinden geldigi** ayni gucle anlasilmiyor.

Metodolojik Duzeltmeler

- Reproducible run klasorleri ve `run_config.json`
- Gercek seed kullanimi ve reproducibility check
- Prompt-template leakage azaltmak icin grouped split
- Coverage saglanmazsa error/warn politikasi
- Raw ve normalized feature sonuclarinin ayrilmasi
- Analitik olarak gecerli gorsellestirme stratejisi

Sinirliliklar ve Gelecek Is

- Sadece iki kucuk model kullanildi.
- Feature set daha zenginlestirilebilir.
- Farkli model aileleri ve daha buyuk modeller denenebilir.
- Kategori yerine farkli hedefler test edilebilir:
  - tekrar davranisi
  - metin kalitesi
  - entropy veya sampling davranisi

Sonuc

Ana cikti

Bu proje, dil modellerinin metin uretirken olusan ic temsil hareketlerinin anlamli sekilde analiz edilebilecegini gosteriyor.

- Trajectory'ler model farkini guclu sekilde tasiyor.
- Ayni feature'lar kategori bilgisini guclu tasimiyor.
- Yani bu calisma daha cok **model behavior analysis** olarak okunmali.

Tesekkurler